Cambios al documento: Variación de la Demanda en el Subte de Buenos Aires

Nov 6, 2026 · @Dante

Cómo usar este borrador

Este borrador contiene sólo el texto que cambia o se agrega en el documento final; lo que no se menciona queda como está. Cada fragmento indica dónde va.

- **Reemplaza a X:** sustituye por completo esa subsección o párrafo.
- **Nueva, después de X:** se inserta a continuación de esa subsección.
- **Se elimina:** se quita del documento.
- **[PENDIENTE: …]:** dato que falta; hoy sólo la capacidad de las formaciones, que afecta los valores absolutos de frecuencia en 4.5.2.

Todas las cifras salen del notebook del repositorio (rama `refactor/notebook-unico`). Las figuras y tablas citadas son los archivos de `output/graficos/` y `output/tablas/`; cada justificación metodológica está en `DECISIONES_METODOLOGICAS.md` (DM-01 a DM-07). La numeración de figuras y tablas sigue el orden de aparición en la Sección 4 y puede ajustarse al maquetar.

Sección 1: Introducción

Los objetivos específicos 2, 3 y 4 y la hipótesis cambian de redacción; el objetivo general y el OE1 se conservan.

1.1 Motivaciones — reemplaza la última oración del segundo párrafo

> Esta es una práctica ya común, como indica el cronograma de servicio vigente, que distingue días hábiles, sábados, y domingos y feriados (*Horarios Del Servicio – Emova*, n.d.).

1.2 Descripción del tema — reemplaza la segunda oración del primer párrafo

> Si la reducción de frecuencias en días no laborables es uniforme entre líneas y horarios, supone implícitamente una contracción idéntica de la demanda en toda la red, e ignora la demanda que persiste en torno a actividades recreativas, culturales o de conexión con terminales de transporte.

1.2 Descripción del tema — reemplaza el paréntesis del segundo párrafo

Donde dice “y el desplazamiento de las horas pico (la alteración cronológica de los momentos de mayor afluencia)”:

> y la distribución horaria de la demanda (cómo se reparte la afluencia a lo largo del día)

Corregir también la errata “aplica,ción”.

1.3.2 Objetivos específicos — reemplaza los objetivos 2, 3 y 4

2. Entrenar y comparar modelos de aprendizaje supervisado y modelos de referencia para proyectar la demanda esperada por estación, tipo de día y ventana horaria de la próxima temporada, con la información disponible antes de su inicio.
3. Cuantificar el ratio de retención y la diferencia en la distribución horaria de la demanda entre tipos de día, tanto en los datos observados como en las proyecciones del modelo para temporadas no observadas.
4. Identificar, para cada línea y tipo de día, las estaciones que determinan la frecuencia mínima requerida para atender la demanda proyectada y los horarios en que lo hacen, con el fin de orientar la optimización de la frecuencia de la línea completa.

1.4 Hipótesis — reemplaza la hipótesis

> La demanda de pasajeros en días no laborables en la red de subtes es estructuralmente no uniforme y presenta diferencias significativas estación por estación, tanto en el ratio de retención respecto de los días hábiles como en la distribución horaria de la demanda.

1.5 Alcance y limitaciones — cambios

- **Ámbito temporal:** reemplazar “se focalizará en la comparación entre los días laborables y no laborables” por “se focalizará en la comparación entre días hábiles, sábados, y domingos y feriados, las tres categorías con que el operador organiza sus cronogramas”.
- **Fuentes de datos:** eliminar la viñeta de información geolocalizada; el modelo usa la identidad de cada estación, que ya captura lo que es fijo por estación.
- **Ausencia de registros de egreso:** reemplazar la última oración por: “Para subsanar metodológicamente esta limitación, el proyecto no evaluará la saturación interna de los trenes, sino la frecuencia mínima requerida para atender la demanda proyectada de cada línea.”
- **Cálculo de oferta y estrés operativo:** reemplazar la viñeta completa por:

> **Frecuencia requerida:** al no contar con la ocupación de cada formación, la demanda proyectada se traduce en la frecuencia mínima que necesita cada línea, dividiéndola por la capacidad nominal publicada de su material rodante. Como los ingresos no se desagregan por sentido y la carga a bordo es desconocida, el resultado es un indicador del orden de magnitud, exacto sólo en las cabeceras.

- **Agregar al final de la lista:**

> **Día típico y días con servicio:** el análisis caracteriza la demanda de los días típicos, con servicio, para fundamentar la diagramación regular. Los días sin servicio (cierres por obras o paros) se excluyen, y los eventos excepcionales, que requieren decisiones operativas específicas, quedan fuera del alcance. El modelo planifica con una temporada de antelación, por lo que no anticipa cambios bruscos de nivel de la demanda.

Sección 2: Marco teórico

Se conservan los antecedentes, la historia del subte y los fundamentos de aprendizaje automático; cambian las métricas de demanda, las series temporales y la comparación de distribuciones. Las citas siguen el formato actual del documento y deben pasarse a IEEE al maquetar.

2 (introducción) — reemplaza la última oración del segundo párrafo

> Por último, presentamos los métodos para comparar perfiles de demanda en sus dos dimensiones, el volumen y la distribución horaria, y la inferencia estadística que se aplica a esa comparación.

2.1.1 y 2.1.3 — agregar al final de cada uno

> A diferencia de este antecedente, que aborda el pronóstico de corto plazo (minutos a horas), el presente trabajo se orienta a la planificación de cronogramas con una temporada de antelación.

2.2.2 Limitaciones — cambios en los puntos 1 y 3

- **Punto 1:** reemplazar “Este enfoque asume erróneamente que la caída del flujo de pasajeros es homogénea en toda la red, ignorando que en estaciones próximas a nodos culturales, comerciales o de transbordo persiste una elevada demanda. El

resultado es una ineficiencia doble: unidades subutilizadas en tramos desiertos y demoras excesivas con hacinamiento en andenes críticos.” por:

> Un esquema de reducción uniforme supone que la caída del flujo de pasajeros es homogénea en toda la red. Si la demanda persiste en estaciones próximas a nodos culturales, comerciales o de transbordo, el resultado sería una ineficiencia doble: formaciones subutilizadas en algunos tramos y oferta insuficiente en otros.

- **Punto 3:** reemplazar la oración final (“Para sortear esta limitación analítica…”) por:

> Para sortear esta limitación, el análisis se apoya en la frecuencia requerida para atender los ingresos registrados (ver 2.2.4.2), que es un indicador del orden de magnitud y sólo es exacta en las cabeceras de línea.

2.2.3 Tipos de día y cronogramas de servicio — nueva, después de 2.2.2

La actual 2.2.3 (Métricas de demanda) pasa a ser 2.2.4.

> El operador organiza el servicio con tres cronogramas: días hábiles, sábados, y domingos y feriados (*Horarios Del Servicio – Emova*, n.d.). Este trabajo adopta las mismas tres categorías: **Hábil** (lunes a viernes que no son feriado), **Sábado** y **Domingo-Feriado** (domingos y feriados nacionales, incluidos los feriados con fines turísticos).
>
> El Jueves Santo es un día no laborable optativo, no un feriado: buena parte de la población trabaja y el operador lo atiende con horario de sábado (*enelsubte.com*, 2024). Por eso se clasifica como Sábado cuando no coincide con otro feriado. La agrupación de domingos y feriados no se asume: se contrasta con los datos en la Sección 4.

2.2.4.1 Curvas de demanda — agregar al final

> Para comparar *cuándo* ocurre la demanda, con independencia de su nivel, cada día se representa por su **perfil normalizado**: la proporción de los ingresos del día que ocurre en cada ventana de 15 minutos. El perfil normalizado describe la **distribución horaria de la demanda**: cómo se reparte la afluencia a lo largo del día. Dos días que difieren sólo en volumen tienen el mismo perfil normalizado, lo que permite comparar tipos de día y estaciones de distinto tamaño.

2.2.3.2 Presión del andén — se elimina

Su contenido pasa a un párrafo de 2.2.4.2.

2.2.4.2 Frecuencia de despacho — agregar al final

> La **frecuencia requerida** para atender una demanda es el cociente entre los abordajes por intervalo y la capacidad útil de cada formación, es decir, su capacidad nominal por una ocupación objetivo (Ceder, 2019). Como la frecuencia se fija para la línea completa, debe alcanzar para la estación de mayor demanda en cada momento, que llamamos **estación determinante**. Cuando la oferta no absorbe la demanda se produce hacinamiento en andenes, lo que motiva el cálculo.

2.2.4.3 Flujo de pasajeros — agregar al final

> Agregado por día, el flujo da el **volumen diario** de cada estación, que es la componente de nivel de la demanda.

2.2.4.4 Ratio de retención de demanda — reemplaza el párrafo posterior a la fórmula

> Numerador y denominador son los ingresos diarios medios de la estación (o de la línea), calculados sobre días con servicio. El ratio se calcula por separado para cada tipo de día no laborable (Sábado y Domingo-Feriado) respecto de los días hábiles, y se informa con un intervalo de confianza (ver 2.5.3). No se somete a contraste de hipótesis: que la demanda no laborable sea menor no está en discusión; lo relevante es su magnitud.

2.3 Machine Learning — reemplaza la lista de dominios de aplicación

> - estimación de la demanda de pasajeros en sistemas de transporte público;
> - predicción de tiempos de viaje y de llegada de vehículos;
> - detección de patrones de uso a partir de datos de validación de tarjetas (Zimmo et al., 2023).

2.3.2 Métricas de evaluación de regresión — correcciones y agregados

- **Corrección en 2.3.2.1:** reemplazar “tiene la ventaja de que penaliza altamente incluso las diferencias pequeñas” por “penaliza con mayor peso los errores grandes: al elevarlos al cuadrado, los errores pequeños se atenúan y los grandes se amplifican”.
- **Corrección en las fórmulas:** las sumatorias van de *i* = 1 a *N*; en la del MAE, la predicción lleva subíndice ($\tilde{y}_i$).
- **Nueva 2.3.2.4, coeficiente de determinación:**

> El coeficiente de determinación mide la proporción de la variabilidad de la variable objetivo que el modelo explica, respecto de predecir siempre su media. Vale 1 si las predicciones son exactas y 0 si no mejoran a la media.

```
R^2 = 1 - \frac{\sum_{i=1}^{N} (y_i - \bar{y}_i)^2}{\sum_{i=1}^{N} (y_i - \langle y \rangle)^2}
```

> Jdonde ⟨y⟩ es la media de los valores reales (Hyndman y Athanasopoulos, 2021).

- **Nueva 2.3.2.5, métricas a nivel de perfil:**

> Para un cronograma, importa menos el error en cada intervalo que la fidelidad del perfil completo de cada estación y tipo de día. Por eso se evalúan también la distancia de variación total entre el perfil proyectado y el observado (ver 2.5.1), el error en el ratio de retención por estación y el error relativo en el volumen diario medio.

2.3.3 Gradient Boosting — corrección y agregado

- **Corrección:** reemplazar la tercera viñeta (“Después de calcular el residuo, se aplican técnicas de regularización…”) por:

> La contribución de cada nuevo predictor se escala por una **tasa de aprendizaje** (*shrinkage*) menor que 1, igual para todos, lo que evita que un solo árbol domine el ajuste. A esto se suman otras formas de regularización, como limitar la profundidad de los árboles o entrenar cada uno con una submuestra de los datos (Friedman, 2001).

- **Agregar al final:**

> En este trabajo se usa XGBoost, una implementación eficiente de *gradient boosting* sobre árboles de decisión (Chen y Guestrin, 2016). Los modelos de árboles no extrapolan: sus predicciones quedan dentro del rango de valores vistos en el entrenamiento, por lo que no pueden proyectar una tendencia. Por esa razón, el modelo de volumen predice el cociente entre el volumen diario y el nivel reciente de la estación, y no el volumen absoluto.

2.3.4 Modelos de referencia — reemplaza a "Modelos de regresión: Regresión lineal"

> Todo modelo predictivo debe compararse con una referencia simple: si no la supera, su complejidad no se justifica (Hyndman y Athanasopoulos, 2021). Se usan dos referencias. El **perfil histórico** predice para cada estación, tipo de día y ventana el promedio de los datos disponibles. El modelo **estacional ingenuo** proyecta el nivel reciente de la estación ajustado por el patrón estacional observado el año anterior, y lo multiplica por su perfil normalizado reciente.

2.4 Series temporales — agregar a la lista de propiedades

> - La **tendencia**: el movimiento de largo plazo del nivel de la serie, como el crecimiento o la caída sostenida de la demanda entre años.

2.4.1 Pronóstico orientado a la planificación — reemplaza a "Modelos de machine learning para series temporales"

> El horizonte de un pronóstico lo fija la decisión que informa. Un cronograma se planifica con antelación, para una temporada completa; el pronóstico sólo puede usar la información disponible antes de que la temporada comience.
>
> Esto define qué variables son admisibles. Los rezagos de corto plazo (el valor de los últimos 15 minutos, de la última hora o del día anterior) no existen al momento de planificar. Sí lo son las variables de calendario, los **rezagos estacionales** (el mismo intervalo un año antes) y los perfiles y niveles históricos calculados a la fecha de inicio de la temporada. Usar cualquier dato posterior constituiría una fuga de datos.
>
> La evaluación respeta el mismo principio mediante el **origen móvil**: para cada temporada de prueba, el modelo se entrena sólo con los datos anteriores a su inicio y la proyecta. Es una extensión de la partición cronológica (*time-based splitting*) que simula el proceso real de planificación y da varias evaluaciones fuera de muestra en lugar de una (Tashman, 2000; Hyndman y Athanasopoulos, 2021).
>
> Por último, la demanda por intervalo se descompone en el producto del **volumen diario** y el **perfil normalizado** del día. La forma del perfil es estable y se estima con los datos recientes; el volumen concentra la incertidumbre, porque depende de la tendencia y del calendario.

2.5 Comparación de perfiles de demanda — reemplaza el título y la introducción

> La comparación entre tipos de día se hace sobre dos dimensiones separadas: el **volumen** (cuánta demanda se mantiene, medido por el ratio de retención) y la **forma** (cómo se distribuye en el día, medida por el perfil normalizado). Una diferencia sólo de volumen no implica una diferencia de forma, y es la forma la que sostiene la afirmación central del trabajo: que la demanda no laborable no es una versión escalada de la hábil.

2.5.1 Perfil normalizado y distancia de variación total — reemplaza a "Método gráfico: Gráfico de densidad (KDE)"

> Sean p_i y q_i las proporciones de la demanda diaria que ingresa en la ventana i en los perfiles medios de dos tipos de día. La **distancia de variación total** compara cada ventana sólo con la misma ventana del otro perfil:

```
TV = \frac{1}{2} \sum_{i=1}^{96} |p_i - q_i| = 1 - \sum_{i=1}^{96} \min(p_i, q_i)
```

> En cada ventana, $\min(p_i, q_i)$ es la porción de la demanda diaria que ambos perfiles comparten; *TV* es la proporción **no compartida** (0 = perfiles idénticos; 1 = sin superposición). Por ejemplo, *TV* = 0,30 indica que el 70% de la distribución horaria coincide entre ambos tipos de día (Gibbs y Su, 2002).
>
> Se prefiere a la distancia de Kolmogorov-Smirnov entre perfiles acumulados porque ésta, aunque coincide con *TV* cuando un perfil está simplemente adelantado respecto del otro, la subestima cuando los perfiles acumulados se cruzan: las diferencias de signo opuesto se compensan. Eso ocurre cuando la demanda se redistribuye a lo largo del día, como en las estaciones céntricas. Para localizar *dónde* difieren los perfiles se usa la **curva de diferencias** por ventana ($q_i - p_i$).

2.5.2 Inferencia por permutación — reemplaza a "Método analítico: Prueba de Kolmogorov-Smirnov"

> Un test de permutación construye la distribución de un estadístico bajo la hipótesis nula a partir de los propios datos, sin suponer su forma (Good, 2005). Si el tipo de día no influye en el perfil, reasignar al azar las etiquetas de tipo de día no debería cambiar sistemáticamente la *TV*; repitiendo la reasignación *B* veces se obtiene su distribución bajo H_0, y el p-valor es la proporción de reasignaciones con una *TV* al menos tan grande como la observada:

```
p = \frac{1 + \#\{TV^{*} \geq TV_{obs}\}}{B + 1}
```

> El 1 agregado incluye la asignación observada y evita p-valores iguales a cero (Phipson y Smyth, 2010). Las etiquetas se reasignan entre **días completos**: los intervalos de un mismo día están correlacionados, y permutar días completos conserva esa dependencia, que invalidaría los p-valores de pruebas que suponen observaciones independientes, como Kolmogorov-Smirnov. El único supuesto es la intercambiabilidad de los días bajo H_0; para que la estacionalidad no la comprometa, las etiquetas sólo se intercambian entre días del mismo año y mes (permutación estratificada).

2.5.3 Intervalos de confianza por bootstrap — nueva

> El *bootstrap* estima la variabilidad de un estadístico remuestreando con reposición los datos observados y recalculándolo en cada remuestreo (Efron y Tibshirani, 1993). Para el ratio de retención se remuestrean fechas completas dentro de cada tipo de día, y los percentiles 2,5 y 97,5 de los ratios recalculados dan un intervalo de confianza del 95%.

2.5.4 Comparaciones múltiples y tamaño de efecto — nueva

> Al contrastar una hipótesis en muchas estaciones a la vez, la probabilidad de obtener algún falso positivo crece con la cantidad de pruebas. La **corrección de Holm** ajusta los p-valores para controlar esa probabilidad en el conjunto, y es válida cualquiera sea la dependencia entre las pruebas (Holm, 1979).
>
> Con miles de días por estación, incluso diferencias pequeñas resultan significativas. El p-valor indica que una diferencia no es atribuible al azar, no que sea relevante; por eso el resultado principal es el **tamaño de efecto** (la *TV* y el ratio de retención con su intervalo), y el p-valor un control complementario (Wasserstein y Lazar, 2016; Sullivan y Feinn, 2012).

Sección 3: Metodología

La sección se reemplaza casi por completo; se conservan el enfoque y la adaptación de CRISP-DM. Eliminar del documento los restos de la plantilla (“Debe hacer una introducción del tópico…”, “Descripción del procedimiento…”) y la Fig. 2 (“Fases (son ejemplos)”).

3 (introducción) — reemplaza los dos párrafos actuales

> El presente trabajo adopta un enfoque cuantitativo, de carácter descriptivo y predictivo, enmarcado en el quehacer de la Ciencia de Datos. Su propósito es caracterizar cómo varía la demanda de pasajeros entre días hábiles y no laborables, y construir un modelo capaz de anticipar la demanda por estación, tipo de día y ventana horaria de la próxima temporada, con la información disponible antes de su inicio, como insumo para el diseño de los cronogramas de servicio. Dado que el problema parte de datos observacionales públicos, el diseño es no experimental: no se manipulan variables, sino que se analizan los registros históricos de operación.
>
> Para ordenar el procedimiento se adopta una adaptación de la metodología CRISP-DM (Cross-Industry Standard Process for Data Mining), ajustada a las particularidades de las series temporales discutidas en el marco teórico (Sección 2.4). El proceso se organiza en ocho fases: comprensión del problema, adquisición y comprensión de los datos, preparación, análisis exploratorio y comparación de perfiles, ingeniería de características, modelado, evaluación y cálculo de métricas operativas.

3.1 Enfoque metodológico y fases — reemplaza el texto y la Tabla 1

> La estrategia combina dos líneas. La primera analiza los datos observados: caracteriza la demanda y contrasta la hipótesis separando su volumen (ratio de retención) de su distribución horaria (perfil normalizado), con inferencia por permutación. La segunda construye un modelo de planificación que proyecta la demanda de la próxima temporada como el producto del volumen diario por la distribución horaria, lo evalúa frente a modelos de referencia y deriva de sus proyecciones las métricas operativas: la retención proyectada y la frecuencia mínima requerida por línea.

Tabla 1. Fases de la metodología y su correspondencia con los objetivos específicos.

Fase	Descripción	Objetivo vinculado
1. Comprensión del problema	Unidades de análisis (día-estación y ventana de 15 min), tipos de día y horizonte de planificación	General

Fase	Descripción	Objetivo vinculado
2. Adquisición y comprensión de datos	Relevamiento de fuentes, verificación de cobertura y diccionario de datos	General
3. Preparación de datos	Parseo de fechas y control de calendario, tipos de día, exclusión de días sin servicio, grilla regular de ventanas	OE1, OE2
4. Análisis exploratorio y comparación de perfiles	Curvas de demanda, retención con intervalos de confianza, distancia de variación total y test de permutación	OE1, OE3, hipótesis
5. Ingeniería de características	Volumen diario y forma; variables a la fecha de origen; rezagos estacionales	OE2
6. Modelado	Modelos de referencia y XGBoost; recomposición volumen × forma	OE2
7. Evaluación	Origen móvil por temporada; métricas por ventana y por perfil	OE2
8. Métricas operativas	Retención proyectada; frecuencia mínima requerida y estaciones determinantes	OE3, OE4

3.2 Fases 1 y 2: comprensión del problema y adquisición de datos — reemplaza los dos primeros párrafos (la Tabla 2 se conserva)

> La variable observada es la cantidad de ingresos registrados por molinete, agregada por estación, fecha y ventana de 15 minutos. Se distinguen dos unidades de análisis: el **día-estación**, para el volumen y la inferencia, porque los intervalos de un mismo día no son independientes; y la **ventana de 15 minutos** dentro de cada día-estación, para la distribución horaria y el modelo. Las categorías de comparación son los tres tipos de día definidos en la Sección 2.2.3: Hábil, Sábado y Domingo-Feriado. El modelo planifica con una temporada de antelación, y se toman como temporadas los trimestres calendario.
>
> La fuente es el conjunto «Subte: Viajes Molinetes» del portal Buenos Aires Data, con un archivo por año entre 2014 y 2019 (más de 70 millones de registros, 41 millones de las Líneas A, B y C). El recorte espacial abarca las líneas A, B y C y sus 44 estaciones; el temporal, de 2014 a 2019.

3.3 Fase 3: preparación y limpieza de datos — reemplaza la lista

> - **Integración y normalización:** los seis archivos anuales, con esquemas distintos (nombres de columnas, codificación de líneas), se unifican en una tabla con clave estación, línea, fecha y ventana horaria. Los nombres de las 44 estaciones, que varían entre años en mayúsculas, tildes y codificación, se mapean a un nombre canónico.
> - **Fechas y control de calendario:** los archivos usan dos formatos de fecha (`AAAA-MM-DD` en 2014, 2015, 2018 y 2019; `DD/MM/AAAA` en 2016 y 2017), que se parsean con formatos explícitos; se valida que cada archivo contenga sólo fechas de su año. Un control de calendario verifica que ningún año tenga domingos con demanda de día hábil, señal de día y mes invertidos.
> - **Tipos de día:** cada fecha se clasifica en Hábil, Sábado o Domingo-Feriado con el calendario de feriados nacionales, incluida la excepción del Jueves Santo (Sección 2.2.3).
> - **Días sin servicio:** se excluyen los días-estación con ingreso total nulo (cierres por obras o paros): la demanda se mide condicionada a la operación del servicio. Dentro de un día con servicio, una ventana sin registros significa que no hubo ingresos y se completa con 0 en una grilla regular de 96 ventanas.
> - **Valores extremos y cierres parciales:** el análisis descriptivo e inferencial usa los valores observados. Sólo en los datos de entrenamiento del modelo, coherente con su propósito de planificar el día típico, los ingresos por ventana que superan el máximo entre el percentil 99,9 y Q3 + 4,5·IQR de su estación y tipo de día se acotan a ese umbral, y los días con ingreso menor al 10% de la mediana de la estación para su tipo de día (cierres parciales) se excluyen; ambos umbrales se calculan sólo con datos anteriores a cada origen de evaluación.

3.4 Fase 4: análisis exploratorio y comparación de perfiles — reemplaza la subsección

> Esta fase responde al primer objetivo específico y contrasta la hipótesis. Se construyen perfiles de demanda por ventana horaria para cada tipo de día, línea y estación, y su estacionalidad mensual. La comparación entre tipos de día se hace en sus dos dimensiones (Sección 2.5):
>
> - **Volumen:** ratio de retención de Sábado y de Domingo-Feriado respecto de Hábil, por línea y por estación, con intervalos de confianza del 95% por *bootstrap* de fechas completas (2.000 remuestreos).
> - **Distribución horaria:** distancia de variación total entre los perfiles normalizados medios de cada par de tipos de día, por estación, y curva de diferencias por ventana en estaciones representativas.
> - **Contraste:** test de permutación de días completos con 10.000 permutaciones, estratificado por año y mes, con corrección de Holm entre las 44 estaciones. Las comparaciones Hábil – Sábado y Hábil – Domingo-Feriado contrastan la hipótesis; Sábado – Domingo-Feriado y Domingo – Feriado validan las categorías (esta última, estratificada por año y trimestre por la escasez de feriados).
>
> Si las distribuciones difieren de manera sistemática y estación por estación, un enfoque único por tipo de día resulta insuficiente y se vuelve necesario un modelo desagregado a nivel de estación.

3.5 Fase 5: ingeniería de características y variables objetivo — reemplaza la subsección

> La demanda por ventana se descompone en volumen diario y forma (Sección 2.4.1), con dos objetivos de modelado. El **volumen diario** por estación se modela como cociente respecto del nivel reciente (promedio de los tres meses anteriores al origen), porque los árboles no extrapolan tendencias. La **forma** es el perfil normalizado medio de los últimos 12 meses por estación y tipo de día, que se estima directamente por su estabilidad.
>
> Todas las variables se calculan a la fecha de inicio de cada temporada, también para las temporadas de entrenamiento:
>
> - **Calendario:** tipo de día, día de la semana, mes, día del mes, feriado, feriado puente, víspera y día posterior a un feriado.
> - **Estación:** identidad de la estación.
> - **Rezago estacional:** el valor de 52 semanas antes.
> - **Niveles y perfiles históricos:** nivel reciente, nivel histórico, factor estacional del año previo, y perfiles medios histórico, del mismo trimestre de años anteriores y de los últimos tres meses.
>
> No se usan rezagos de corto plazo (15 minutos, una hora, un día o una semana), que no estarían disponibles al planificar.

3.6 Fase 6: modelado — reemplaza la subsección

> Se comparan cuatro modelos de decisión por temporada, con la misma información admisible:
>
> 1. **Perfil histórico:** promedio por estación, tipo de día y ventana de los datos anteriores al origen. Es la línea base.
> 2. **V1 × forma (estacional ingenuo):** nivel de los últimos tres meses multiplicado por el factor estacional del año previo (cociente entre ese trimestre del año anterior y los tres meses que lo precedieron), por la forma de los últimos 12 meses.
> 3. **XGBoost directo:** predice los ingresos por ventana a partir de las variables admisibles. Es la estructura alternativa, que permite evaluar el efecto de separar volumen y forma.
> 4. **V2 × forma:** XGBoost predice el cociente del volumen diario respecto del nivel reciente; el volumen resultante se multiplica por la forma.
>
> Los hiperparámetros de ambos modelos XGBoost se eligen con la misma grilla (profundidad de los árboles, 4 u 8; entrenamiento con todos los años o sólo con los dos últimos) y el mismo criterio, el RMSE por ventana promedio sobre los cuatro trimestres de 2018. La opción de años de entrenamiento es el tratamiento común del nivel para ambos.

3.7 Fase 7: validación y evaluación — reemplaza la subsección

> La evaluación aplica el origen móvil por temporada (Sección 2.4.1): cada trimestre de 2019 se proyecta con un modelo entrenado sólo con los datos anteriores a su inicio, usando el trimestre inmediatamente anterior para la detención temprana. Los resultados se comparan siempre contra los valores observados, sin acotar y con todos los días con servicio.
>
> El desempeño se mide en dos niveles: **por ventana**, con RMSE, MAE, R^2 y sesgo de volumen (Sección 2.3.2), y **por perfil** de estación y tipo de día, con la distancia de variación total entre perfil proyectado y observado, el error en el ratio de retención y el error en el volumen medio. El criterio de adopción se fijó antes de la evaluación final: el modelo con aprendizaje automático se adopta si supera al estacional ingenuo en todas las métricas; si no, se adopta este último.

3.8 Fase 8: cálculo de métricas operativas — reemplaza la subsección

> Con las proyecciones del modelo adoptado para las temporadas de 2019 se calculan:
>
> - **Retención proyectada:** ratio de retención por estación para Sábado y Domingo-Feriado, comparado con el observado.
> - **Frecuencia mínima requerida:** para cada línea, tipo de día y ventana, el máximo entre sus estaciones de los ingresos proyectados, dividido por la capacidad útil por formación (capacidad nominal de la flota actual por la ocupación objetivo). Se expresa en trenes por ventana o como intervalo máximo entre trenes. La estación que impone el máximo es la estación determinante. Como los ingresos no se desagregan por sentido y la carga a bordo es desconocida, es un indicador del orden de magnitud, exacto sólo en las cabeceras.
> - **Estaciones determinantes (OE4):** para cada línea y tipo de día, las estaciones que determinan la frecuencia requerida y los horarios en que lo hacen.

3.9 Herramientas y reproducibilidad — reemplaza la subsección (y deja de numerarse como fase)

> La implementación se desarrolla en Python, con pandas y NumPy para la manipulación de datos, matplotlib y seaborn para la visualización, la biblioteca `holidays` como fuente del calendario de feriados nacionales y XGBoost para el modelado. Las dependencias se declaran y fijan con el gestor uv, de modo que el entorno puede reproducirse exactamente.
>
> Todo el procedimiento se ejecuta en un único notebook de Jupyter, que regenera de principio a fin los datos procesados, las tablas y las figuras; su enlace se incluye en la sección de Soporte digital. Las decisiones metodológicas y su justificación se documentan en un registro de decisiones dentro del mismo repositorio, como parte de la trazabilidad del trabajo.

Sección 4: Propuesta de solución

Reemplaza la Sección 4 completa. Cada resultado se presenta en tres bloques (qué muestra, cómo se interpreta, qué aporta); se elimina el resto de la plantilla (“Debe hacer una introducción…”). Entre corchetes, el archivo de figura o tabla del repositorio.

Introducción (dos párrafos, sin título de subsección)

> En esta sección se presentan los resultados de aplicar la metodología descrita en la Sección 3 a los registros de ingreso por molinete de las Líneas A, B y C del Subte de Buenos Aires entre 2014 y 2019: más de 70 millones de registros, consolidados en ventanas de 15 minutos para las 44 estaciones de la red. El análisis se organiza en torno a una distinción central: la variación de la demanda entre tipos de día tiene dos dimensiones, el volumen (cuánta demanda se mantiene) y la distribución horaria (cómo se reparte a lo largo del día), y cada una responde a una decisión distinta de la diagramación del servicio: cuántas formaciones despachar y en qué franjas.
>
> Los resultados siguen el orden de los objetivos específicos. Primero se describe la calidad de los datos y se caracterizan las curvas de demanda (OE1). Luego se cuantifican el volumen y la distribución horaria de la variación entre tipos de día y se contrasta la hipótesis (OE1 y OE3). A continuación se evalúa el modelo predictivo, orientado a planificar el cronograma de una temporada con la información disponible antes de su inicio (OE2). Por último, se derivan de sus proyecciones la retención proyectada y la frecuencia mínima requerida por línea, con las estaciones que la determinan (OE3 y OE4).

4.1 Datos procesados y control de calidad

> **Qué muestra:** La Tabla 4.1 resume la cobertura de los datos: 70.095.421 registros brutos, de los cuales 41.086.314 corresponden a las Líneas A, B y C, consolidados en las 44 estaciones entre 2014 y 2019 [`01_resumen_nulos_limpieza.md`]. Cada año tiene alrededor de 245 días hábiles, 51 sábados y 68 domingos y feriados. Se reclasificaron como Sábado cuatro Jueves Santos no coincidentes con otros feriados, y se trataron como feriados 12 feriados puente.
>
> **Cómo se interpreta:** Se excluyeron 360 días-estación sin ingresos (209 en domingos y feriados, 122 en días hábiles y 29 en sábados), concentrados en cierres dominicales por obras. La retención de la red cambia menos de 0,4 puntos porcentuales según se incluyan o no esos días, de modo que los resultados no dependen de ese tratamiento. El control de calendario confirma que ningún año presenta domingos con demanda de día hábil.
>
> **Qué aporta:** Acredita que los resultados descansan sobre un calendario verificado y sobre una población explícita: los días con servicio.

4.2 Caracterización de las curvas de demanda (OE1)

> **Qué muestra:** La Fig. 4.1 presenta el perfil horario medio de la red por tipo de día [`01_curva_demanda_dia_semana.png`]; la Fig. 4.2, el mismo perfil por línea [`03_perfil_horario_por_linea.png`]; la Fig. 4.3, el de cuatro estaciones representativas: San Pedrito (origen residencial), Florida (centro financiero), Constitución (transbordo intermodal) y Carlos Gardel (polo recreativo) [`04_comparativa_habil_nolab_estaciones_clave.png`]; y la Fig. 4.4, el volumen diario medio por mes y tipo de día [`02_curva_demanda_estacional_mes.png`].
>
> **Cómo se interpreta:** Los días hábiles siguen un patrón bimodal, con picos matutino (07:30–09:30) y vespertino (17:00–19:30). Los sábados forman una meseta centrada cerca del mediodía y los domingos y feriados alcanzan su máximo al atardecer; en ninguno de los dos persisten los picos laborales, salvo un pico matutino de los sábados en la Línea C, asociado a Constitución. La demanda cae en enero y febrero y se recupera desde marzo en los tres tipos de día.
>
> **Qué aporta:** Primera evidencia del OE1: la demanda no laborable no es una versión escalada de la hábil sino un régimen de uso distinto, y sábados y domingos-feriados difieren entre sí. La estacionalidad justifica planificar por temporada.

4.3 Variación entre tipos de día: volumen y distribución horaria (OE1, OE3, hipótesis)

4.3.1 Volumen: ratio de retención

Tabla 4.2. Ratio de retención por línea respecto de los días hábiles, días con servicio, 2014–2019 (IC 95% por bootstrap) [`03_ratios_retencion_linea.md`].

Línea	Retención Sábado (%)	Retención Domingo-Feriado (%)
Línea A	38,82 [37,82 – 39,88]	18,16 [17,61 – 18,72]
Línea B	37,21 [35,92 – 38,41]	20,28 [19,64 – 20,92]
Línea C	40,92 [39,79 – 42,01]	21,54 [20,87 – 22,19]
Red (A, B, C)	38,59 [37,47 – 39,72]	19,80 [19,20 – 20,37]

> **Qué muestra:** La Tabla 4.2 y la Fig. 4.5 [`05_retencion_por_estacion_ic.png`] presentan la retención por línea y por estación, con sus intervalos de confianza.
>
> **Cómo se interpreta:** La red retiene el 38,59% de la demanda hábil los sábados y el 19,80% los domingos y feriados. El promedio oculta brechas amplias: en el Microcentro la retención cae a 18,47% (Plaza de Mayo) y 18,76% (Diagonal Norte) los sábados, y a 9,18% (Diagonal Norte) y 9,22% (Florida) los domingos y feriados; Carlos Gardel, junto al Shopping Abasto, retiene el 72,19% los sábados y el 55,53% los domingos y feriados. Constitución mantiene el mayor volumen absoluto: 37.298 pasajeros diarios los sábados y 17.851 los domingos y feriados.
>
> **Qué aporta:** Cuantifica la retención del OE3 sobre los datos observados y muestra que la caída de la demanda no es uniforme entre estaciones.

4.3.2 Distribución horaria: distancia entre perfiles

> **Qué muestra:** La Fig. 4.6 presenta, para cada estación, la distancia de variación total entre su perfil normalizado hábil y el de cada tipo de día no laborable [`07_tv_distribucion_horaria_por_estacion.png`]. La Fig. 4.7 muestra, en las estaciones representativas, la diferencia por ventana entre ambos perfiles, con su banda simultánea al 95% [`08_diferencias_por_ventana_estaciones_representativas.png`].
>
> **Cómo se interpreta:** La mediana de la distancia es 0,169 para los sábados (rango 0,085–0,313) y 0,186 para los domingos y feriados (rango 0,075–0,413). Las mayores diferencias se dan en cabeceras residenciales y de transbordo: Echeverría, Juan Manuel de Rosas, Constitución y San Pedrito superan 0,40 en domingos y feriados, porque la demanda se traslada de la mañana a la tarde. En la mayoría de las estaciones del Microcentro (Florida, Plaza de Mayo, Piedras, Perú) la diferencia es mayor los sábados: ambos tipos de día pierden el pico vespertino de regreso, pero los sábados concentran además la demanda cerca del mediodía.
>
> **Qué aporta:** Cuantifica la diferencia en la distribución horaria del OE3 y localiza las franjas en que ocurre, que es la información accionable para la diagramación: dónde reforzar o reducir el servicio.

4.3.3 Contraste de la hipótesis

Tabla 4.3. Distancia de variación total entre perfiles normalizados por estación y test de permutación (10.000 permutaciones, corrección de Holm entre 44 estaciones) [`05_distribucion_horaria_tv_permutacion.md`].

Comparación	TV mediana [mín – máx]	p ajustado (Holm) máximo
Hábil – Sábado	0,169 [0,085 – 0,313]	0,0044
Hábil – Domingo-Feriado	0,186 [0,075 – 0,413]	0,0044
Sábado – Domingo-Feriado	0,165 [0,090 – 0,302]	0,0044
Domingo – Feriado	0,049 [0,022 – 0,085]	0,4714

> **Qué muestra:** La Tabla 4.3 resume las cuatro comparaciones; el detalle por estación y por línea está en el archivo de la tabla.
>
> **Cómo se interpreta:** En las comparaciones de la hipótesis, la diferencia es significativa en las 44 estaciones, con el menor p-valor ajustado alcanzable (0,0044). Dado el volumen de datos, la significancia es esperable; lo relevante es el tamaño de efecto, que varía casi cinco veces entre estaciones. Sábados y domingos-feriados difieren entre sí tanto como cada uno respecto de los días hábiles. Domingos y feriados, en cambio, tienen distribuciones muy similares (TV mediana 0,049, sin diferencia significativa en 5 estaciones) y niveles de retención comparables (18,96% y 22,21%).
>
> **Qué aporta:** Respalda la hipótesis de heterogeneidad estación por estación, tanto en volumen como en distribución horaria, y valida con los datos la clasificación en Hábil, Sábado y Domingo-Feriado.

4.4 Modelo predictivo para la planificación por temporada (OE2)

> Cada trimestre de 2019 se proyectó con modelos entrenados sólo con datos anteriores a su inicio (Sección 3.7). Los dos modelos XGBoost eligieron profundidad 8 en el ajuste sobre 2018; el directo, entrenando con los dos últimos años, y V2 × forma, con todos.

Tabla 4.4. Desempeño por ventana de 15 minutos en 2019, origen móvil por trimestre [`07_modelo_desempeno_por_ventana.md`].

Modelo	RMSE (pax/15 min)	MAE (pax/15 min)	R^2	Sesgo de volumen
Perfil histórico	64,65	25,64	0,923	−5,2%
V1 × forma	61,65	22,61	0,930	+2,4%
XGBoost directo	59,25	23,93	0,936	+6,3%

Modelo	RMSE (pax/15 min)	MAE (pax/15 min)	R^2	Sesgo de volumen
V2 × forma	59,11	21,77	0,936	+5,7%

Tabla 4.5. Desempeño por perfil de estación y tipo de día en 2019 [`08_modelo_desempeno_por_perfil.md`].

Modelo	TV de forma (mediana)	Error retención Sábado (pp)	Error retención Domingo-Feriado (pp)	Error de volumen medio	Error diario mediano
Perfil histórico	0,030	3,80	1,14	10,1%	12,6%
V1 × forma	0,018	1,23	0,69	3,8%	8,4%
XGBoost directo	0,043	3,07	4,57	19,5%	9,8%
V2 × forma	0,018	0,80	0,75	6,8%	7,7%

Qué muestra: Las Tablas 4.4 y 4.5 comparan los cuatro modelos; la Fig. 4.8 contrasta los perfiles observados y proyectados por el modelo adoptado en una temporada de 2019 [`09_perfiles_observados_vs_proyectados.png`], y la Fig. 4.9 muestra el sesgo de volumen por temporada y tipo de día [`10_sesgo_volumen_por_temporada.png`].

Cómo se interpreta: Los tres modelos mejoran a la línea base. Por ventana, los dos XGBoost son los más precisos (RMSE de 59). Pero el XGBoost directo es el peor en lo que determina un cronograma: sobreestima el volumen de los domingos y feriados en 21% y su error de volumen medio llega a 19,5%. Separar volumen y forma corrige ese problema: ambos modelos que lo hacen reproducen la forma con una distancia mediana de 0,018 y la retención con errores menores a 1,3 puntos. V2 × forma mejora la variación entre días y la retención de los sábados, pero sobreestima el nivel de 2019 en 5,7%, presumiblemente por proyectar el crecimiento de los años previos; V1 × forma está mejor calibrado (sesgo de 2,4%, error de volumen medio de 3,8%). El nivel de los domingos y feriados es la componente más incierta para todos los modelos: V1 lo sobreestima en 24% en el primer trimestre y lo subestima en 15% en el tercero.

Qué aporta: Responde el OE2. Conforme al criterio fijado antes de la evaluación, como V2 no supera a V1 en todas las métricas, se adopta **V1 × forma**. El resultado es negativo para la adopción del aprendizaje automático con este horizonte: con una temporada de antelación, la estructura estacional y la separación entre volumen y forma explican la mayor parte de lo que XGBoost captura, y la incertidumbre se concentra en el nivel de la demanda.

4.5 Métricas operativas proyectadas (OE3 y OE4)

4.5.1 Retención proyectada

> **Qué muestra:** La Tabla 4.6 compara, para cada estación, la retención proyectada por el modelo adoptado para 2019 con la observada [`09_retencion_proyectada_vs_observada.md`].
>
> **Cómo se interpreta:** El error medio es de 1,23 puntos porcentuales en los sábados y de 0,69 en los domingos y feriados: la retención de cada estación puede anticiparse con una temporada de antelación.
>
> **Qué aporta:** Completa el OE3 con proyecciones para temporadas no observadas por el modelo, que es lo que requiere la planificación.

4.5.2 Frecuencia mínima requerida y estaciones determinantes

Tabla 4.7. Estaciones determinantes de la frecuencia requerida por línea y tipo de día, franjas de una hora, proyección del modelo adoptado para 2019 [`10_estaciones_determinantes.md`]. Se omiten las horas sin demanda proyectada y los tramos de una sola hora en los extremos del día.

Línea	Tipo de día	Estaciones determinantes (horarios)	Demanda máxima (pax/hora)
A	Hábil	San Pedrito[1] (05–15 h), Perú (15–22 h)	5.359
A	Sábado	San Pedrito[1] (05–19 h, 21–22 h), Acoyte (19–21 h)	2.106
A	Domingo-Feriado	San Pedrito[1] (06–22 h)	534
B	Hábil	Federico Lacroze (05–07 h, 08–15 h), Juan Manuel de Rosas[1] (07–08 h), Leandro N. Alem[1] (16–20 h), Carlos Pellegrini (20–22 h)	5.825
B	Sábado	Federico Lacroze (05–15 h), Carlos Gardel (15–23 h)	1.348
B	Domingo-Feriado	Federico Lacroze (05–15 h), Carlos Gardel (15–23 h)	1.020
C	Hábil	Constitución[1] (05–17 h, 20–22 h), Retiro[1] (17–20 h, 22–24 h)	14.197

Línea	Tipo de día	Estaciones determinantes (horarios)	Demanda máxima (pax/hora)
C	Sábado	Constitución[1] (05–24 h)	5.142
C	Domingo-Feriado	Constitución[1] (05–23 h)	2.110

[1] Cabecera de línea: la frecuencia requerida es exacta. En el resto es un indicador del orden de magnitud.

> **Qué muestra:** La Tabla 4.7 identifica, para cada línea y tipo de día, las estaciones de mayor demanda proyectada en cada hora, que determinan la frecuencia que necesita la línea completa. La Fig. 4.10 muestra la demanda a absorber por hora y su estación determinante [`11_frecuencia_requerida_por_linea.png`]. [PENDIENTE: con la capacidad de las formaciones, la figura pasa a expresarse en trenes por hora.]
>
> **Cómo se interpreta:** Pocas estaciones determinan la frecuencia de cada línea. En la Línea C, Constitución lo hace durante casi todo el día en los tres tipos de día, salvo el regreso vespertino hábil, que corresponde a Retiro. En la Línea A, San Pedrito determina la mañana hábil y casi todo el fin de semana, y Perú la tarde hábil. En la Línea B, Federico Lacroze determina las mañanas de los tres tipos de día, mientras que por la tarde la determinan Leandro N. Alem en días hábiles y Carlos Gardel los sábados, domingos y feriados. Como la capacidad es constante dentro de cada línea, la frecuencia requerida en la hora de mayor exigencia guarda la misma proporción que la demanda: los sábados es del 39% (Línea A), 23% (B) y 36% (C) de la del pico hábil, y los domingos y feriados del 10%, 18% y 15%.
>
> **Qué aporta:** Responde el OE4 y traduce la proyección de demanda en la variable de decisión del problema: la frecuencia por línea, y qué estaciones y horarios la condicionan. Muestra además que el patrón de la estación determinante cambia entre tipos de día (en la Línea B, el polo recreativo de Carlos Gardel pasa a determinar la tarde no laborable), lo que una reducción proporcional uniforme no captura.

4.6 Correspondencia con objetivos e hipótesis

Tabla 4.8. Síntesis de resultados por objetivo.

Objetivo	Resultado principal	Evidencia
OE1	La demanda no laborable sigue regímenes propios: meseta de mediodía los sábados, máximo al atardecer los domingos y feriados	Fig. 4.1 a 4.4
OE2	Con una temporada de antelación, el modelo estacional V1 × forma reproduce la retención con errores menores a 1,3 pp; XGBoost no lo supera en volumen	Tablas 4.4 y 4.5, Fig. 4.8 y 4.9
OE3	Retención de 38,59% (sábados) y 19,80% (domingos y feriados), entre 9% y 72% según la estación; distribución horaria distinta en todas las estaciones	Tablas 4.2, 4.3 y 4.6, Fig. 4.5 a 4.7
OE4	Pocas estaciones determinan la frecuencia de cada línea (Constitución, San Pedrito, Federico Lacroze, Carlos Gardel); en su hora de mayor exigencia, la frecuencia requerida es del 23% al 39% de la hábil los sábados y del 10% al 18% los domingos y feriados	Tabla 4.7, Fig. 4.10
Hipótesis	Confirmada en volumen y distribución horaria, estación por estación; el tamaño de efecto varía casi cinco veces entre estaciones	Tabla 4.3

> **Limitaciones:** los ingresos no permiten conocer la ocupación de los trenes ni el sentido de viaje; el modelo no anticipa cambios bruscos de nivel de la demanda; y el análisis caracteriza días típicos, sin eventos excepcionales.

Sección 5: Conclusiones

Reemplaza la Sección 5 completa, incluidas las recomendaciones; se elimina el texto de la plantilla que la sigue.

El presente trabajo analizó la variación de la demanda de pasajeros en las Líneas A, B y C del Subte de Buenos Aires entre 2014 y 2019, distinguiendo días hábiles, sábados, y domingos y feriados, y separando el volumen de la demanda de su distribución a lo largo del día. Los resultados responden a cada objetivo planteado:

1. **Caracterización de las curvas de demanda (OE1).** La demanda no laborable no es una versión escalada de la hábil. Frente al patrón bimodal de los días hábiles, los sábados forman una meseta cercana al mediodía y los domingos y feriados alcanzan su máximo al atardecer, con una caída común en enero y febrero.
2. **Modelo predictivo (OE2).** Se entrenaron y compararon modelos de aprendizaje supervisado bajo las mismas condiciones que los modelos de referencia, proyectando cada temporada de 2019 con la información disponible antes de su inicio. XGBoost mejora la precisión en ventanas de 15 minutos, pero sobreestima el nivel de 2019; según el criterio fijado antes de la evaluación, se adoptó el modelo estacional, mejor calibrado en volumen. Con una temporada de antelación, la estructura estacional y la separación entre volumen y forma explican la mayor parte de lo que el aprendizaje automático captura.
3. **Retención y distribución horaria (OE3).** La red retiene el 38,59% de la demanda hábil los sábados y el 19,80% los domingos y feriados, pero la retención va del 9% en el Microcentro al 72% en Carlos Gardel. La distribución horaria difiere significativamente en las 44 estaciones, con mayor intensidad en las cabeceras residenciales y de transbordo. El modelo adoptado anticipa la retención de cada estación con errores medios menores a 1,3 puntos porcentuales.
4. **Frecuencia requerida (OE4).** Traducida a la frecuencia que necesita cada línea, la demanda proyectada depende de pocas estaciones: Constitución en la Línea C durante casi todo el día; San Pedrito y Perú en la Línea A; y en la Línea B, Federico Lacroze por la mañana y, por la tarde, Leandro N. Alem en días hábiles y Carlos Gardel en jornadas no laborables. En la hora de mayor exigencia, la frecuencia requerida es del 23% al 39% de la del pico hábil los sábados y del 10% al 18% los domingos y feriados.

La hipótesis se confirma: la demanda en días no laborables es estructuralmente no uniforme y presenta diferencias significativas estación por estación, tanto en la retención como en la distribución horaria.

Recomendaciones operativas para la planificación del transporte — reemplaza las tres viñetas actuales

> - **Diferenciar los cronogramas por tipo de día y por estación:** sábados y domingos-feriados constituyen regímenes distintos, y una reducción proporcional igual para toda la red no refleja retenciones que varían entre el 9% y el 72%.
> - **Planificar la distribución horaria con una temporada de antelación y monitorear el nivel:** la forma de los perfiles es estable y se proyecta con precisión; el nivel de la demanda, sobre todo en domingos y feriados, es la componente incierta, que conviene ajustar con datos recientes durante la temporada.
> - **Fijar la frecuencia de cada línea a partir de sus estaciones determinantes:** la frecuencia debe alcanzar para la estación de mayor demanda, y ésta cambia con el tipo de día y la hora. En la Línea B, por ejemplo, la tarde no laborable la determina Carlos Gardel y no las cabeceras, y en la Línea C la determina Constitución también los fines de semana.
> - **Incorporar registros de egreso:** permitirían pasar de la frecuencia requerida como indicador a una estimación de la ocupación de los trenes.

Resumen y palabras clave

Reemplazan el resumen vacío y las palabras clave de la plantilla (“x, y, z”).

Resumen. Los cronogramas del Subte de Buenos Aires reducen la frecuencia en días no laborables, pero la demanda no cae de manera uniforme. Este trabajo analiza más de 70 millones de registros de molinete de las Líneas A, B y C entre 2014 y 2019, en ventanas de 15 minutos y para tres tipos de día: hábiles, sábados, y domingos y feriados. Se separa el volumen de la demanda, medido por el ratio de retención con intervalos de confianza por bootstrap, de su distribución horaria, medida por la distancia de variación total entre perfiles normalizados y contrastada con un test de permutación. La red retiene el 38,59% de la demanda hábil los sábados y el 19,80% los domingos y feriados, con valores entre el 9% y el 72% según la estación, y la distribución horaria difiere significativamente en las 44 estaciones. Para planificar, se compararon modelos que proyectan la demanda de la próxima temporada con la información disponible antes de su inicio. Un modelo estacional que combina el volumen diario con la distribución horaria reciente anticipa la retención de cada estación con errores menores a 1,3 puntos porcentuales, sin que el aprendizaje automático (XGBoost) lo supere en la calibración del volumen. Las proyecciones se traducen en la frecuencia mínima requerida por línea y en las estaciones que la determinan.

Palabras clave: demanda de transporte público, subterráneo, días no laborables, ratio de retención, distribución horaria, test de permutación, pronóstico estacional, frecuencia de servicio.

Referencias nuevas

Agregar a la Sección 6. Verificar edición y datos de cada una antes de pasarlas a formato IEEE. Pueden quitarse Conover (1999), Bontempi (2013) y Silverman (2018), que ya no se citan.

- Chen, T., y Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- Efron, B., y Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- *enelsubte.com* (2024, 27 de marzo). Cronograma de servicio de Subte para la Semana Santa. Enlace
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5), 1189–1232.
- Gibbs, A. L., y Su, F. E. (2002). On choosing and bounding probability metrics. *International Statistical Review*, 70(3), 419–435.
- Good, P. (2005). *Permutation, Parametric, and Bootstrap Tests of Hypotheses* (3.ª ed.). Springer.

- Holm, S. (1979). A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2), 65–70.
- Hyndman, R. J., y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts. Enlace
- Phipson, B., y Smyth, G. K. (2010). Permutation P-values should never be zero. *Statistical Applications in Genetics and Molecular Biology*, 9(1).
- Sullivan, G. M., y Feinn, R. (2012). Using effect size—or why the P value is not enough. *Journal of Graduate Medical Education*, 4(3), 279–282.
- Tashman, L. J. (2000). Out-of-sample tests of forecasting accuracy: An analysis and review. *International Journal of Forecasting*, 16(4), 437–450.
- Wasserstein, R. L., y Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician*, 70(2), 129–133.
- [PENDIENTE: fuente de la capacidad del material rodante de cada línea y estándar de densidad de pie.]